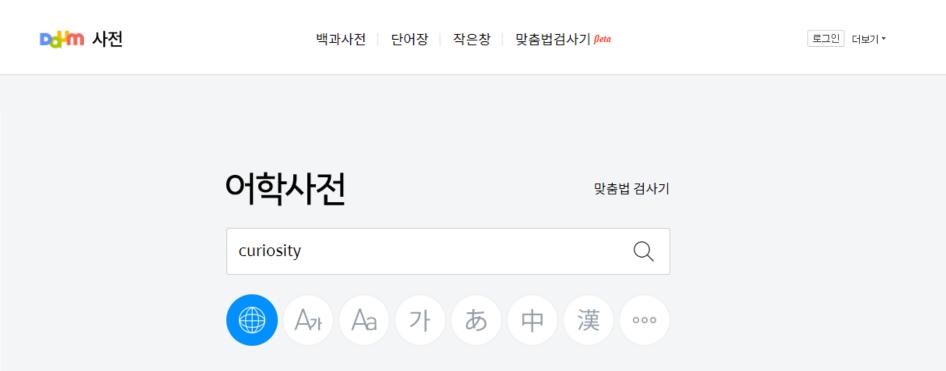
Web Crawling 실습

비정형 데이터 분석을 통한 효율적인 의사결정 박진수 교수

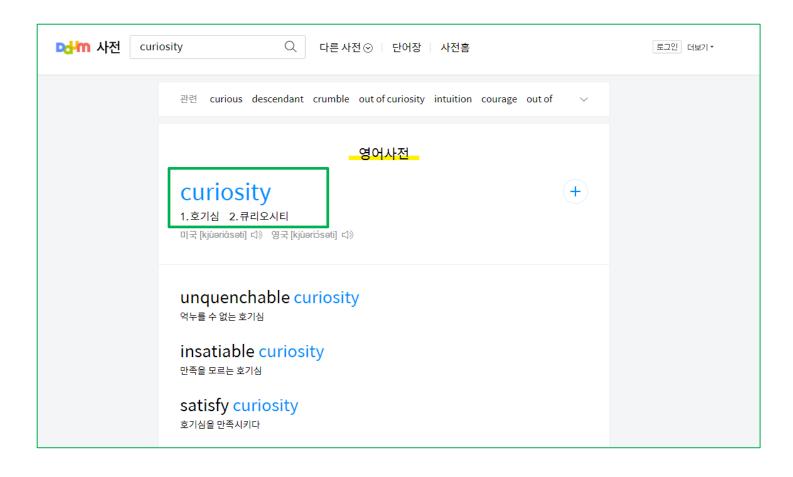
Big Data Institute, Seoul National University

실습 1 - 다음 사전



실습 1-1. 단어의 검색 결과 출력하기

- · 다음 어학사전(http://dic.daum.net/index.do?dic=all)에 'curiosity' 단어를 검색하였을 때 출력 되는 화면에서 가장 상단의 결과를 출력한다
 - 영어 단어의 의미(본 예제에서는 '1. 호기심 2. 큐리오시티')를 출력한다



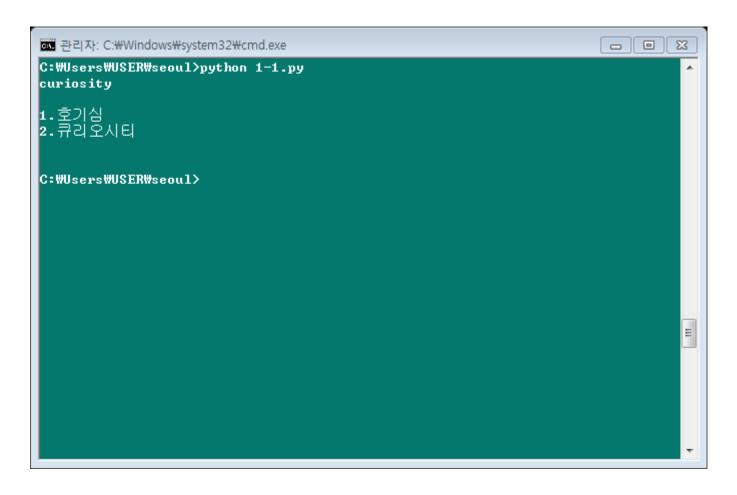
실습 1-1. 단어의 검색 결과 출력하기

· TIPS

- 가져오고자 하는 텍스트의 다른 HTML 구성요소와 구분되는 특성(CSS style)을 잘 생각해 본다
- 가장 상단에 있는 데이터임을 고려하면서 HTML 파싱 결과를 어떻게 슬라이싱(slicing)할 것인지 고민해 본다

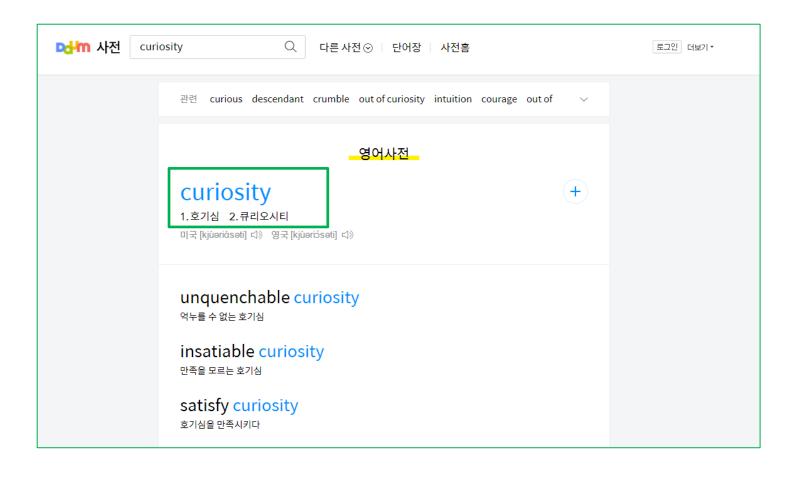
실습 1-1. 단어의 검색 결과 출력하기

· 출력 결과



실습 1-2. 여러 단어의 검색 결과 출력하기

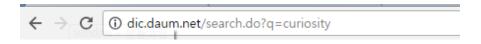
- · 다음 어학사전(http://dic.daum.net/index.do?dic=all)에 'curiosity', 'killed', 'the', 'cat' 4개 단어를 검색 하였을 때 출력 되는 화면에서 가장 상단의 결과를 출력한다
 - 영어 단어의 의미를 출력한다



실습 1-2. 여러 단어의 검색 결과 출력하기

· TIPS

- 초기 화면에서 몇 개 단어를 검색해 보면서 URL 구조를 잘 생각해 본다



- for 문을 활용해 여러 단어를 돌아가면서 데이터를 출력한다

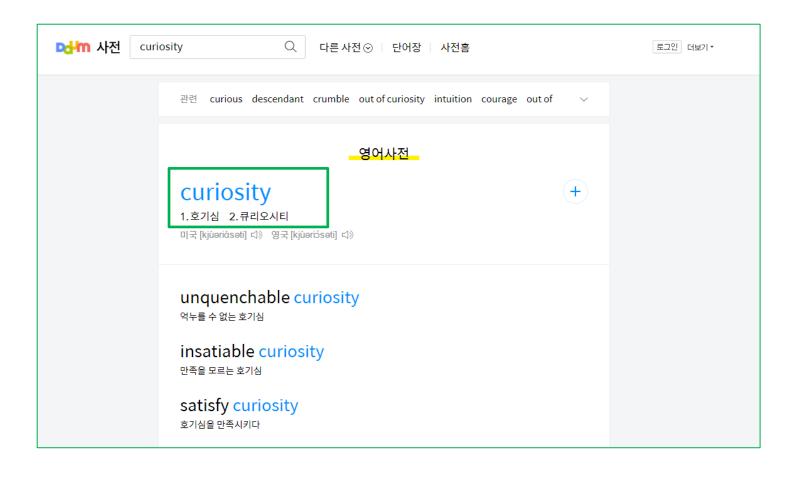
실습 1-2. 여러 단어의 검색 결과 출력하기

· 출력 결과

```
 관리자: C:₩Windows₩system32₩cmd.exe
                                                                           C:\Users\USER\seoul>python 1-2.py
curiosity
1.호기심
2.큐리오시티
killed
1.죽음
2.사망
3.살해되다
4.목숨을 잃다
the
cat
1.고양이
2.고양이과 동물
```

실습 1-3. 여러 단어의 검색 결과 저장하기

- · 다음 어학사전(http://dic.daum.net/index.do?dic=all)에 'curiosity', 'killed', 'the', 'cat' 4개 단어를 검색 하였을 때 출력 되는 화면에서 가장 상단의 결과를 텍스트 파일에 저장한다
 - 영어 단어의 의미를 저장한다



실습 1-3. 여러 단어의 검색 결과 저장하기

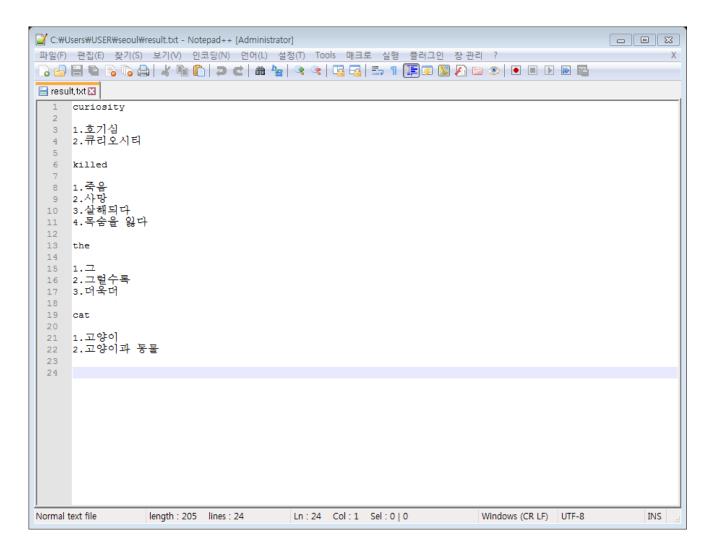
·TIPS

- 파이썬의 open 함수를 사용해 텍스트 파일로 저장한다

- 한글 저장을 위해 인코딩을 'utf-8'로 설정한다

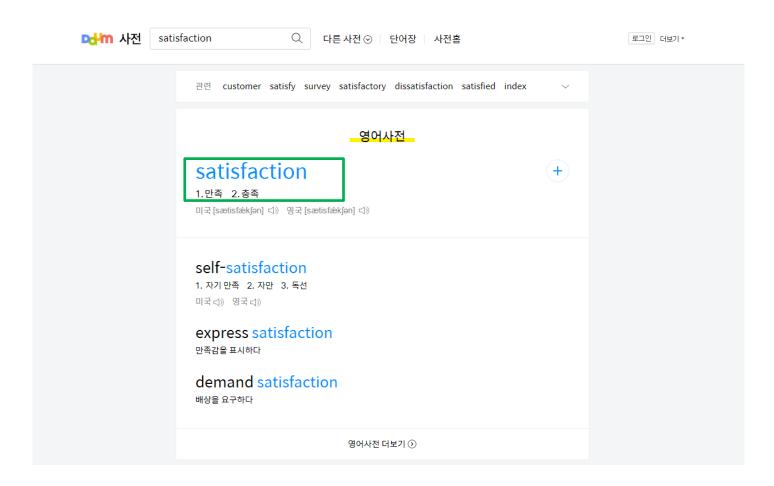
실습 1-3. 여러 단어의 검색 결과 저장하기

ㆍ저장 결과



실습 1-4. 여러 단어를 불러와 검색 결과 저장하기

- · 다음 어학사전(http://dic.daum.net/index.do?dic=all)에 텍스트 파일(data.txt)에 있는 각 단어를 검색하였을 때 출력 되는 화면에서 가장 상단의 결과를 텍스트 파일에 저장한다
 - 영어 단어의 의미를 저장한다



실습 1-4. 여러 단어를 불러와 검색 결과 저장하기

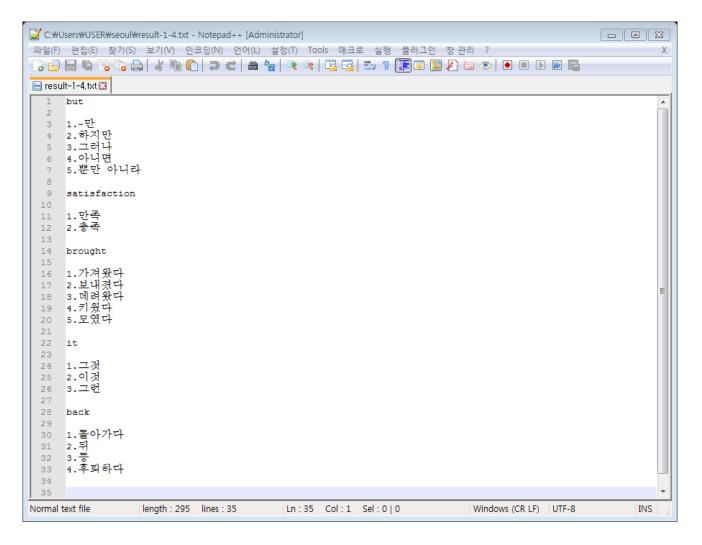
·TIPS

- 텍스트 파일의 내용을 불러올 때 readlines 함수를 사용한다

- 한글 저장을 위해 인코딩을 'utf-8'로 설정한다

실습 1-4. 여러 단어를 불러와 검색 결과 저장하기

ㆍ저장 결과

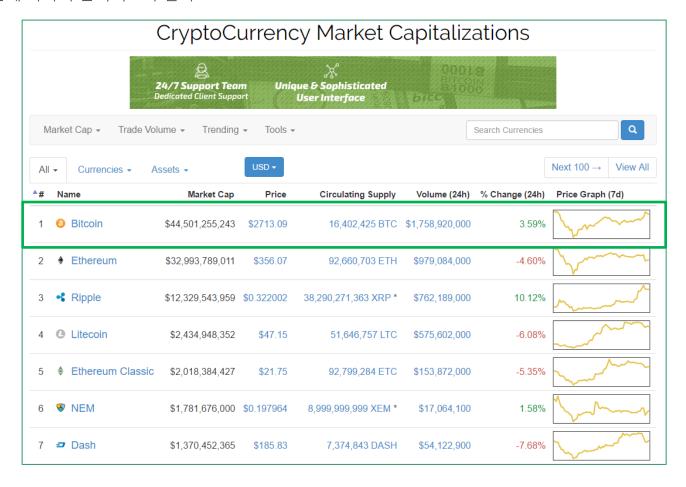


실습 2 – Coinmarketcap.com



실습 2-1. 비트코인 관련 데이터 출력하기

- · 코인마켓캡(https://coinmarketcap.com/) 메인 페이지에서 가장 상단에 있는 비트코인의 화폐 이름 (Name)과 시가총액(Market Cap), 개당 가격(Price), 그리고 24시간 볼륨(Volume)을 출력해 본다
 - 한 줄에 하나씩 출력되도록 한다

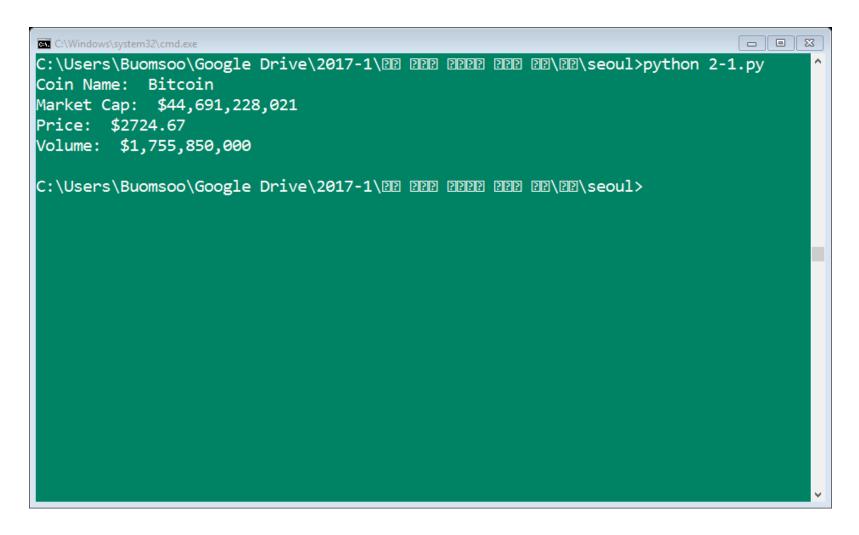


실습 2-1. 비트코인 관련 데이터 출력하기

- ·TIPS
 - 분할 정복(Divide and Conquer)
 - 우선 전체 코인 데이터가 포함되어 있는 테이블(table)을 찾는다
 - 테이블 내에 비트코인 데이터가 있는 행(tr)을 찾는다

실습 2-1. 비트코인 관련 데이터 출력하기

· 출력 결과



실습 2-2. 상위 100개 코인 관련 데이터 저장하기

- · 코인마켓캡(<u>https://coinmarketcap.com/</u>) 메인 페이지에 있는 상위 100개 코인의 화폐 이름(Name)과 시가총액(Market Cap), 개당 가격(Price), 그리고 24시간 볼륨(Volume)을 텍스트 파일로 저장한다
 - 한 줄에 코인 하나의 데이터를 저장하고, 각 행에서는 탭으로 구분한다



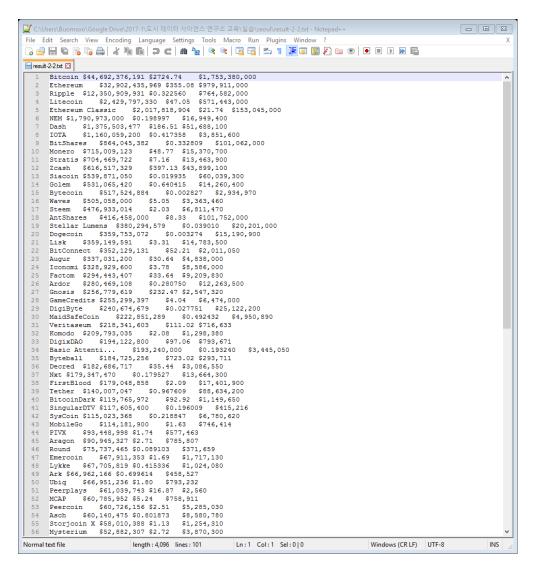
실습 2-2. 상위 100개 코인 관련 데이터 저장하기

· TIPS

- 실습 2-1에서 활용했던 코드를 조금만 바꾸면 쉽게 풀 수 있다
- for문을 활용해 텍스트 파일에 코인 하나씩 데이터를 write한다

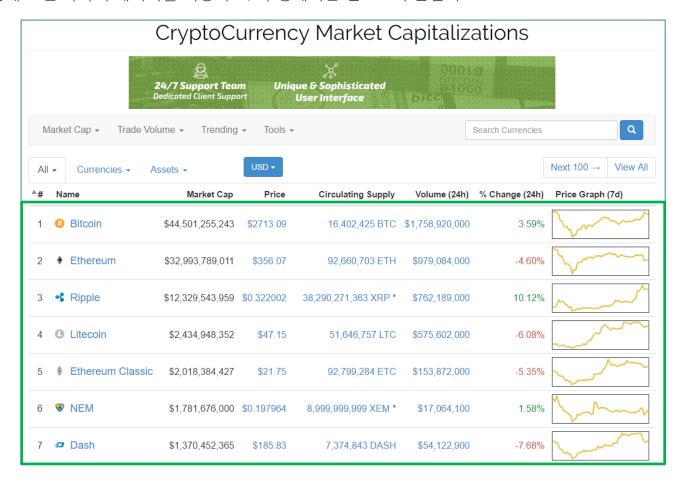
실습 2-2. 상위 100개 코인 관련 데이터 저장하기

ㆍ 저장 결과



실습 2-3. 특정 조건을 만족하는 코인 관련 데이터 저장하기

- · 상위 100개의 코인 중 24시간 볼륨(Volume)이 \$1,000,000 이상이고 개당 가격이 \$50 이상인 코인들의 데이터만 저장한다
 - 한 줄에 코인 하나의 데이터를 저장하고, 각 행에서는 탭으로 구분한다



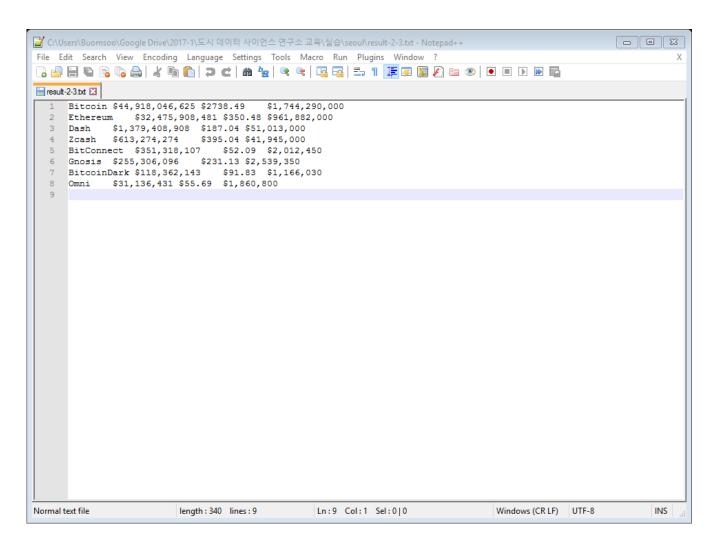
실습 2-3. 특정 조건을 만족하는 코인 관련 데이터 저장하기

· TIPS

- 각 코인의 개당 가격과 볼륨에서 replace 함수를 사용해 '\$', ',' 등 기호들을 제거한다
- 가격과 볼륨을 float 데이터 타입으로 변환한다
- If문을 활용해 조건을 만족하는 코인의 데이터만 저장한다

실습 2-3. 특정 조건을 만족하는 코인 관련 데이터 저장하기

ㆍ 저장 결과



실습 3 - IMDb



실습 3-1. 영화 정보 출력하기

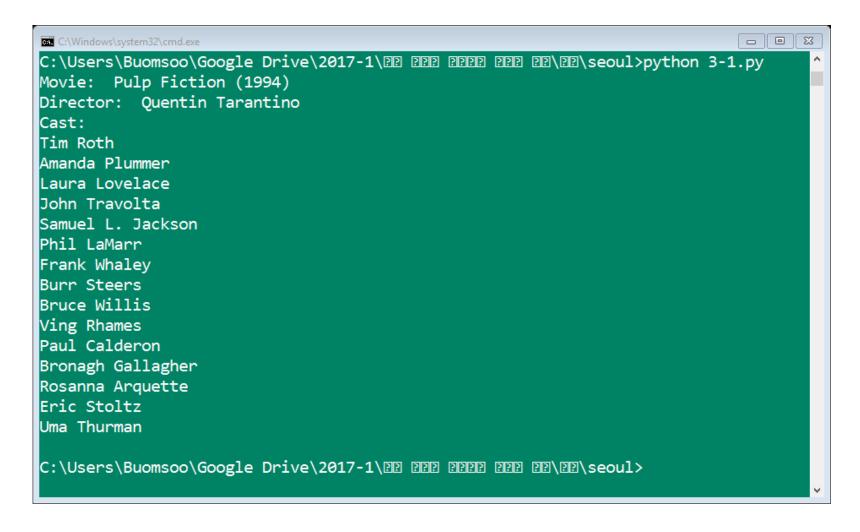
· IMDb 사이트에서 영화 펄프 픽션 페이지(<u>http://www.imdb.com/title/tt0110912/?ref_=nv_sr_1</u>)에서 펄 프 픽션 영화의 제목(title)과 감독(director), 그리고 출연 배우(cast)를 출력한다





실습 3-1. 영화 정보 출력하기

· 출력 결과



실습 3-2. 여러 영화 정보 저장하기

- · 영화 펄프 픽션(Pulp Fiction), 포레스트 검프(Forrest Gump), 그리고 다크 나이트(The Dark Knight)의 제목(title)과 감독 이름(director)를 텍스트 파일에 저장한다
 - 영화 하나당 한 줄씩 출력되도록 한다



실습 3-2. 여러 영화 정보 저장하기

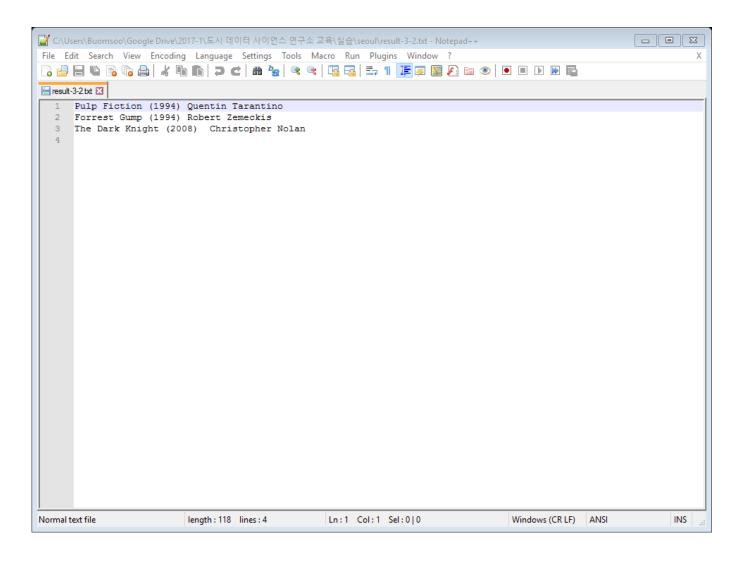
·TIPS

- 영화가 달라짐에 따라 각 영화 정보의 URL이 어떻게 변하는지 잘 살펴본다



실습 3-2. 여러 영화 정보 저장하기

ㆍ저장 결과



실습 3-3. 영화 리뷰 출력하기

· 영화 다크 나이트(The Dark Knight)의 리뷰 페이지에 들어가 첫 번째 리뷰 내용을 출력해 보자



실습 3-3. 영화 리뷰 출력하기

· TIPS

- Table의 구성요소 중 'p' 태그를 가진 요소를 모두 찾는다
- 'p' 태그 중 내용에 'This review may contain spoilers' 및 'Add another review'가 포함된 태그를 제외하고 출력한다
- if문과 break를 활용해 첫 번째 리뷰만 출력한다
- replace함수를 이용해 불필요한 공백을 제거한다('\r', '\n' 등)

실습 3-3. 영화 리뷰 출력하기

· 출력 결과

C:\Windows\system32\cmd.exe C:\Users\Buomsoo\Google Drive\2017-1\22 222 222 222 22\22\seoul>python 3-3.py We've been subjected to enormous amounts of hype and marketing for the Dark Knight. We've seen Joker scavenger hunts and one of the largest viral campaigns in advertising history and it culminates with the actual release of the movie.Everything that's been said is pret ty much spot on. This is the first time I can remember where a summer blockbuster film far surpasses the hype. For as much action as there is in this movie, it's the acting that mak es it a great piece of work. Between all the punches, explosions and stunt-work is some gr eat dialog work. All the actors have their moments.Bale's Batman is the definitive Batman because we see everything in this character finally on film. Martial arts skills, cunning, great tactical thinking, forensic application, technological genius to advance or improve Luscious Fox's inventions/technological breakthroughs, intimidating personality, and even a little swashbuckling. As for Heath, yes he gets credit for his performance as the Joker . But you have to also recognize Jonathan and Chris Nolan for the writing and treatment of the character. It's not just the fact that Ledger makes the Joker so menacing, but the No lans have given the character this great manifesto that drives its actions. The Joker's st ance on chaos, order, anarchy, the morality of the average modern human being make the cha racter so interesting psychologically. The Nolans drafted a complex character and only a p erfect performance could've pulled something like this off. That's how difficult of a role this was, and that's why Ledger's performance is so great. This isn't an action movie. It' s a film that explores literary themes of the hero and villain, as well as order and anarc hy. Yes, listen to the dialog because it's all in there.

실습 3-4. 영화 리뷰 저장하기

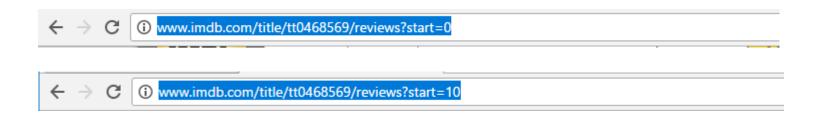
- · 영화 다크 나이트(The Dark Knight)의 첫 번째 부터 10번째 페이지까지의 리뷰를 텍스트 파일에 저장 한다
 - 총 100개의 리뷰가 저장되어야 한다



실습 3-4. 영화 리뷰 저장하기

· TIPS

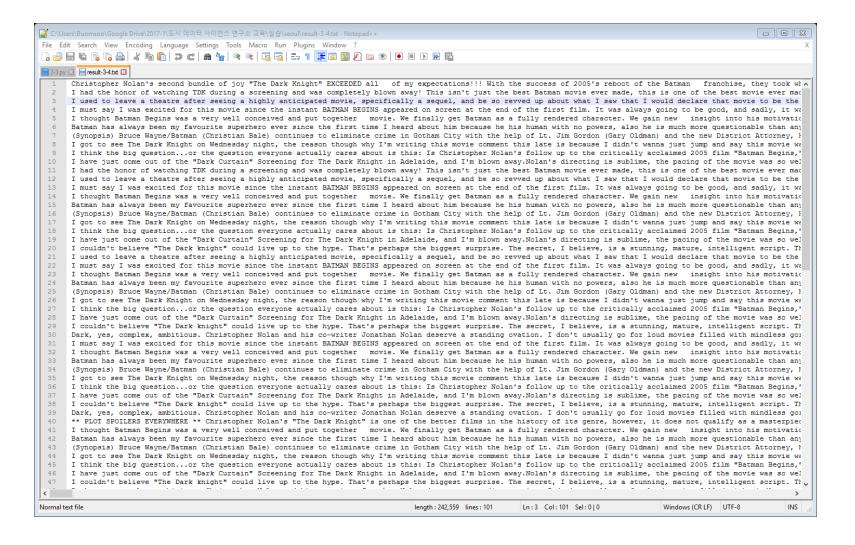
- 영화 리뷰 페이지의 페이지 번호를 바꾸어 가면서 URL 구조를 세심히 살펴보자



- While 문을 활용해 영화 리뷰를 페이지마다 모두 저장한다(while문 마지막에 구문 탈출 조건 명시)
- replace함수를 이용해 불필요한 공백을 제거한다('\r', '\n' 등)
- 파일을 저장할 때 인코딩(encoding) 설정을 꼭 'utf-8'으로 한다

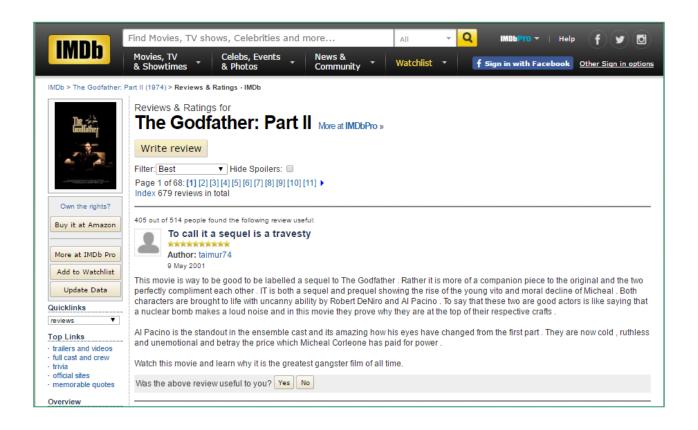
실습 3-4. 영화 리뷰 저장하기

ㆍ 저장 결과



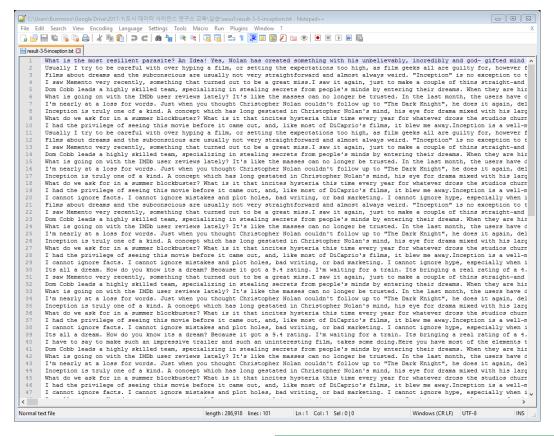
실습 3-5. 영화 리뷰 저장하기(2)

- · 자신이 좋아하는 영화를 3개 이상 골라 3-4의 코드를 조금씩 바꾸어 영화 리뷰를 각각 다른 텍스트 파일에 저장해 본다
 - 리뷰를 영화 별로 최소한 100개 이상 수집한다



실습 3-5. 영화 리뷰 저장하기(2)

ㆍ저장 결과



result-3-5-inception	21/06/2017 17:40	Text Document	281 KB
result-3-5-old_boy	21/06/2017 17:42	Text Document	181 KB
🗾 result-3-5-whiplash	21/06/2017 17:41	Text Document	216 KB